

Disciplina de Inteligência Artificial , Professor Munif , Unicesumar - 2026

Integrantes

- Vinicius Reginaldo Ferrarini — RA: 23159293-2
 - Pedro Alvaro Mantuani Silva — RA: 23079477-2
 - Luiz Henrique Peschieira Romano — RA: 25363238-2
-

1. Resumo do Projeto

1.1 Contextualização

O acesso à água potável é reconhecido pela Organização Mundial da Saúde (OMS) como um direito humano fundamental. Apesar disso, milhões de pessoas ao redor do mundo ainda consomem água contaminada, resultando em doenças graves e mortes evitáveis. A análise laboratorial tradicional da qualidade da água é eficaz, porém lenta e cara. Nesse contexto, o uso de Inteligência Artificial surge como alternativa promissora para automatizar e agilizar o processo de classificação da potabilidade da água com base em parâmetros físico-químicos.

1.2 Problema

O objetivo deste projeto é desenvolver e comparar modelos de IA capazes de classificar amostras de água como potáveis ou não potáveis, utilizando métricas físico-químicas do dataset "Water Quality". A questão central é: é possível prever, com confiança, se uma amostra de água é segura para consumo humano a partir de dados laboratoriais?

1.3 Hipótese

Nossa hipótese é que modelos de IA conseguem classificar a potabilidade da água com acurácia satisfatória a partir de atributos físico-químicos, e que a Rede Neural Artificial (RNA) tende a superar o Naive Bayes, dado que a RNA é capaz de capturar relações não-lineares mais complexas entre os atributos.

2. Dataset

2.1 Descrição Geral

- Nome: Water Quality (Potability)
- Origem: Kaggle — <https://www.kaggle.com/datasets/mssmartypants/water-quality>
- Quantidade de registros: 7.999 amostras
- Formato: CSV tabular
- Variável alvo: is_safe (1 = potável, 0 = não potável) — classificação binária

2.2 Atributos do Dataset

Atributo	Descrição
aluminium	Concentração de alumínio (mg/L)
ammonia	Concentração de amônia (mg/L)
arsenic	Concentração de arsênico (mg/L)
barium	Concentração de bário (mg/L)
cadmium	Concentração de cádmio (mg/L)
chloramine	Concentração de cloramina (mg/L)
chromium	Concentração de cromo (mg/L)
copper	Concentração de cobre (mg/L)
flouride	Concentração de fluoreto (mg/L)
bacteria	Presença de bactérias (0 ou 1)
viruses	Presença de vírus (0 ou 1)
lead	Concentração de chumbo (mg/L)
nitrate	Concentração de nitratos (mg/L)
nitrite	Concentração de nitritos (mg/L)
mercury	Concentração de mercúrio (mg/L)
perchlorate	Concentração de perclorato (mg/L)

radium	Concentração de rádio (pCi/L)
selenium	Concentração de selênio (mg/L)
silver	Concentração de prata (mg/L)
uranium	Concentração de urânio (mg/L)
is_safe	VARIÁVEL ALVO — 1 = potável, 0 = não potável

2.3 Preparação dos Dados

- Carregamento: leitura do arquivo CSV com a biblioteca pandas.
- Tratamento de valores ausentes: remoção de linhas com valores NaN.
- Separação de features e target: variáveis independentes (X) separadas de is_safe (y).
- Normalização: StandardScaler — média 0, desvio padrão 1
- Divisão treino/teste: 80% treino / 20% teste com random_state=42 para reprodutibilidade.

3. Métodos de Inteligência Artificial

3.1 Método da Parte 1 — Naive Bayes Gaussiano

O Naive Bayes Gaussiano é um classificador probabilístico fundamentado no Teorema de Bayes. Assume que todas as features são independentes entre si e que seguem distribuição gaussiana. Apesar da simplicidade, serve como boa baseline em problemas de classificação.

```
from sklearn.naive_bayes import GaussianNB
modelo_nb = GaussianNB()
modelo_nb.fit(X_train_scaled, y_train)
y_pred_nb = modelo_nb.predict(X_test_scaled)
```

3.2 Método da Parte 2 — Rede Neural Artificial (RNA)

A Rede Neural Artificial é um modelo inspirado no funcionamento do cérebro humano, composto por camadas de neurônios artificiais que aprendem padrões complexos e não-lineares. A arquitetura utilizada foi:

- Camada de entrada: 20 neurônios (um por feature)
- 1ª camada oculta: 64 neurônios — ativação ReLU


- 2ª camada oculta: 32 neurônios — ativação ReLU
 - Camada de saída: 1 neurônio — ativação Sigmoid (saída probabilística 0–1)
 - Otimizador: Adam | Função de perda: Binary Crossentropy | Épocas: 50 | Batch: 32
- ```
modelo_rna = Sequential([
 Dense(64, activation='relu', input_shape=(X_train.shape[1],)),
 Dense(32, activation='relu'),
 Dense(1, activation='sigmoid')
])
modelo_rna.compile(optimizer='adam',
 loss='binary_crossentropy',
 metrics=['accuracy'])
historico = modelo_rna.fit(X_train_scaled, y_train,
 epochs=50, batch_size=32,
 validation_split=0.2)
```
- 

## 4. Avaliação dos Modelos


### 4.1 Métricas Utilizadas

- **Acurácia:** proporção de classificações corretas sobre o total.
- **Precisão:** dos exemplos classificados como positivos, quantos realmente são.
- **Recall (Revocação):** dos exemplos positivos reais, quantos foram corretamente identificados.
- **F1-Score:** média harmônica entre precisão e recall.
- **Matriz de Confusão:** visualização dos acertos e erros por classe.
- **Curva de Perda e Acurácia (RNA):** acompanhamento do aprendizado ao longo das épocas.


## 4.2 Matriz de Confusão (Naive Bayes Gaussiano)




### 4.3 Matriz de Confusão (RNA)



#### 4.4 Curva de Acurácia (RNA)




#### 4.5 Curva de Perda (RNA)



## 5. Comparação dos Resultados

| Métrica  | Naive Bayes     | Rede Neural (RNA) |
|----------|-----------------|-------------------|
| Acurácia | 0.8444 (84.44%) | 0.9444 (94.44%)   |
| Precisão | 0.4169          | 0.8208            |
| Recall   | 0.6150          | 0.7100            |
| F1-Score | 0.4970          | 0.7614            |



### 5.1 Análise Comparativa

O Naive Bayes, por assumir independência entre as features, pode perder desempenho em situações onde há correlação entre os atributos físico-químicos. No contexto de qualidade da água, é razoável esperar que variáveis como concentração de metais pesados e presença de bactérias apresentem dependências entre si, o que limita a eficácia do modelo.

A Rede Neural Artificial é capaz de aprender representações hierárquicas e relações não-lineares entre as variáveis, tendendo a maior capacidade de generalização. O custo é um maior tempo de treinamento e necessidade de ajuste de hiperparâmetros. A comparação foi baseada principalmente na acurácia e no F1-Score, pois em um contexto de potabilidade da



água, tanto os falsos positivos (classificar água contaminada como segura) quanto os falsos negativos (descartar água segura) têm impacto relevante na saúde pública.

---

## 6. Conclusão

Este trabalho demonstrou o processo completo de desenvolvimento de uma solução baseada em Inteligência Artificial para o problema de classificação da potabilidade da água. Foram aplicados dois modelos distintos: o Naive Bayes Gaussiano (Parte 1 da disciplina) e a Rede Neural Artificial (Parte 2 da disciplina), ambos treinados e avaliados sobre o mesmo dataset.

A escolha do dataset "Water Quality" mostrou-se adequada ao problema, por conter atributos físico-químicos reais e uma variável alvo bem definida, tornando o problema diretamente aplicável ao contexto de saúde pública e ambiental.

Os resultados obtidos confirmaram a hipótese inicial: a RNA alcançou 94,44% de acurácia contra 84,44% do Naive Bayes, demonstrando maior capacidade de capturar as relações não-lineares entre os atributos físico-químicos da água. O F1-Score da RNA (0,76) também superou significativamente o do Naive Bayes (0,49), indicando melhor equilíbrio entre precisão e recall.

---

## 7. Estrutura do Repositório e Execução

### 7.1 Como obter o dataset

- Acesse: [Water quality](#)
- Faça o download do arquivo waterQuality1.csv
- Renomeie para water\_quality.csv e coloque na raiz do projeto

### 7.2 Como executar

```
pip install pandas numpy scikit-learn tensorflow matplotlib seaborn joblib
jupyter notebook water_quality.ipynb
```

### 7.3 Como carregar os modelos salvos

```
import joblib

from tensorflow.keras.models import load_model

modelo_nb = joblib.load('modelos/modelo_naive_bayes.pkl')
modelo_rna = load_model('modelos/modelo_rna.h5')
```